

Lösung von AsteroidStatic mit Deep Reinforcement Learning

Task 2 – Deep Reinforcement Learning (Prof. Thomas Nierhoff, OTH Amberg-Weiden)

Autor: Himanshu Mohan Nikam

Matrikelnummer: 25901848

1. Projektüberblick

Das Projekt besteht aus mehreren eigenen Dateien. Die vorgegebene Datei `asteroid.py` wurde nicht verändert:

- `stoch_actor_critic.py` – stochastischer Actor-Critic (One-step, on-policy).
- `DDPG.py` – Deep Deterministic Policy Gradient.
- `TD3.py` – Twin Delayed DDPG.
- `tune_stochastic_ac.py`, `tune_ddpg.py`, `tune_td3.py` – Optuna-Tuning für die jeweilige Methode.
- `eval_*.py` sowie die zugehörigen Tuning-Logs, Optuna-Datenbanken (`*.db`), die besten Konfigurationen (`best_*.json`) und die Auswertungsergebnisse (`eval_*_results.json`).

Gemessen werden die beiden geforderten Zielgrößen, jeweils gemittelt über zehn Arenen (Seeds 0 bis 9): erstens die Anzahl der Umgebungsaufrufe bis zum erstmaligen Erreichen des Ziels (Metrik 1, Stichprobeneffizienz) und zweitens die kürzeste erfolgreiche Episodenlänge (Metrik 2, Geschwindigkeit). Zusätzlich wird die Anzahl der Aufrufe festgehalten, bei der diese kürzeste Episode zuerst auftrat. Für das Tuning werden andere Seeds (115 und 119) benutzt als für die finale Auswertung.

2. Ansätze

Die Umgebung besitzt einen kontinuierlichen Aktionsraum, weshalb alle drei umgesetzten Verfahren direkt auf dem Vektor $a = [a_x, a_y]$ arbeiten. Untersucht wurden ein on-policy Verfahren und zwei off-policy Verfahren.

2.1 On-policy: Stochastischer Actor-Critic (in `stoch_actor_critic.py`)

Dieses Verfahren folgt der Vorlesungsformulierung des One-step Actor-Critic. Der Actor ist eine stochastische Gauß-Politik $\pi(a|s, \theta)$, die Mittelwert und Streuung ausgibt; die Aktion wird aus dieser Verteilung gezogen. Der Critic schätzt den Zustandswert $V(s, w)$. Beide werden mit demselben TD-Fehler $\delta = R + \gamma \hat{V}(S', w) - \hat{V}(S, w)$ aktualisiert, der Critic über δ^2 und der Actor über $-\log \pi(a|s) \delta$. Zusätzlich wird ein Entropiebonus addiert, der die Streuung der Politik offen hält, sowie der Faktor $I \leftarrow \gamma I$ aus der Vorlesungsfolie verwendet. Die Exploration entsteht hier ausschließlich durch das Ziehen aus der Verteilung.

2.2 Off-policy: DDPG (in `DDPG.py`)

DDPG ersetzt die stochastische Politik durch einen deterministischen Actor $\mu(s)$ und den Zustandswert durch einen Aktionswert $Q(s, a)$. Dadurch wird das Verfahren off-policy und kann einen Replay Buffer nutzen, was für die Stichprobeneffizienz wichtig ist. Der Actor wird über den deterministischen Policy-Gradienten trainiert, also in Richtung steigender Q -Werte. Stabilisiert wird das Ganze durch Zielnetze mit weichen Polyak-Updates und durch zeitlich korreliertes Ornstein-Uhlenbeck-Rauschen, das die Exploration liefert.

2.3 Off-policy: TD3 (in TD3.py)

TD3 erweitert DDPG um drei Punkte. Erstens werden zwei Critics gelernt und im Ziel das Minimum beider verwendet, was die typische Überschätzung der Aktionswerte dämpft. Zweitens wird auf die Zielaktion ein begrenztes Rauschen addiert (Target Policy Smoothing), damit der Critic keine scharfen Ausreißer im Q -Verlauf ausnutzen kann. Drittens wird der Actor seltener aktualisiert als die Critics, damit die Wertschätzung dem Actor vorauseilt.

2.4 Weitere erprobte Ansätze

Vor den drei eingereichten Verfahren wurde auch die DQN-Familie umgesetzt und getestet (DQN, Double DQN und Dueling DDQN). Da DQN einen endlichen Aktionsraum benötigt, wurde die Aktion dafür in neun Bang-Bang-Aktionen diskretisiert, also alle Kombinationen aus $\{-1, 0, +1\}$ für a_x und a_y . Dieser Ansatz löste einzelne Arenen zuverlässig, ist aber nicht Teil der Abgabe, da der Schwerpunkt auf den Verfahren für kontinuierliche Aktionen liegt.

3. Wichtige Techniken

- **Eingangsnormalisierung.** Positionen und Geschwindigkeiten werden anhand der bekannten Grenzen der Umgebung auf einen vergleichbaren Bereich skaliert. Es handelt sich um eine reine Skalierung der Eingänge und nicht um eine Analyse der Umgebung. Ohne diesen Schritt war keines der Verfahren stabil trainierbar.
- **Asymmetrisches Reward-Clipping.** Die Kollisionsstrafe von -100 ist rund zwei Größenordnungen größer als der Fortschrittsterm von $0,5 \cdot \text{Fortschritt}$. Dadurch kollabieren die gelernten Werte auf einen nahezu konstanten negativen Wert, und der Agent kann gute von schlechten Aktionen nicht mehr unterscheiden. Die Strafe wird deshalb nach unten begrenzt, während der Zielbonus von $+10$ unverändert groß bleibt. So bleiben die seltenen erfolgreichen Übergänge das dominierende Signal.
- **Exploration.** Ein rein zufälliger Agent erreicht das Ziel nur in etwa $0,2\%$ der Episoden und auf mehreren Arenen überhaupt nicht. Die Exploration muss daher dauerhaft stark bleiben. Beim stochastischen Actor-Critic übernimmt das der Entropiebonus, bei DDPG und TD3 das korrelierte Ornstein-Uhlenbeck-Rauschen.
- **Begrenzung der Streuung.** Die Streuung der Gauß-Politik wird über `log_std` gelernt und auf einen festen Bereich begrenzt. Ohne diese Begrenzung wächst sie durch den Entropiebonus unbegrenzt an, bis die Verteilung ungültig wird (siehe Abschnitt 6).
- **Stabilität.** Zusätzlich werden Gradienten begrenzt, Zielnetze verwendet und der Replay Buffer vor dem ersten Update mit zufälligen Übergängen gefüllt.

4. Hyperparameter Tuning

Die Hyperparameter werden mit Optuna gesucht, für jede Methode in einem eigenen Skript und einer eigenen SQLite-Datenbank, sodass unterbrochene Läufe fortgesetzt werden können. Getunt werden unter anderem die Lernraten von Actor und Critic, γ , die Netzgröße sowie die methodenspezifischen Parameter, also τ und die Rauschstärke bei DDPG und TD3 beziehungsweise der Entropiekoeffizient beim stochastischen Actor-Critic.

Die Tuning-Seeds sind von den Auswertungs-Seeds getrennt. Um geeignete Tuning-Seeds zu finden, wurden die Kandidaten 100 bis 119 zunächst mit einem Zufallsagenten vermessen. Auf den meisten davon wird das Ziel nie zufällig erreicht, sodass das Tuning dort kein verwertbares Signal liefert. Gewählt wurden deshalb die Seeds 115 und 119, auf denen der Zufallsagent das Ziel

zumindest gelegentlich erreicht. Die Zielfunktion minimiert die Aufrufe bis zur ersten Lösung; Konfigurationen, die innerhalb des Episodenbudgets nicht lösen, werden ersatzweise nach ihrem geringsten Abstand zum Ziel bewertet, damit die Suche auch dann eine Richtung hat.

Tabelle 1: Beste von Optuna gefundene Konfiguration je Verfahren.

Hyperparameter	Stoch. Actor-Critic	DDPG	TD3
Actor-Lernrate	offen	$1,7 \cdot 10^{-5}$	$1,4 \cdot 10^{-4}$
Critic-Lernrate	offen	$4,8 \cdot 10^{-4}$	$1,9 \cdot 10^{-3}$
γ	offen	0,992	0,962
τ (Polyak)	–	$1,8 \cdot 10^{-3}$	$8,0 \cdot 10^{-3}$
Rauschstärke	offen	$\sigma_{OU} = 0,37$	$\sigma_{OU} = 0,32$
Target Policy Smoothing	–	–	0,34 / 0,50
Policy Delay	–	–	1
Batch-Größe	offen	128	128
Netzgröße	offen	256	256

5. Ergebnisse

Jedes Verfahren wird mit seiner besten Konfiguration auf den Seeds 0 bis 9 ausgewertet, mit einem Budget von 5000 Episoden je Seed. Tabelle 2 zeigt, wie viele Arenen gelöst wurden und die Mittelwerte über die jeweils gelösten Seeds. Die Auswertung des stochastischen Actor-Critic steht noch aus und wird nachgetragen.

Tabelle 2: Ergebnisse auf den Auswertungs-Seeds 0 bis 9, gemittelt über die jeweils gelösten Seeds.

Verfahren	Gelöste Seeds	Metrik 1	Metrik 2	Zugehörige Aufrufe
Stoch. Actor-Critic	offen	offen	offen	offen
DDPG	5/10	4.473	24,2	88.761
TD3	10/10	89.295	37,9	147.919

Die Mittelwerte beziehen sich jeweils nur auf die von einem Verfahren gelösten Seeds und sind deshalb nicht unmittelbar vergleichbar. TD3 löst als einziges Verfahren auch die beiden schwersten Arenen (Seeds 4 und 8), die lange Wege von 83 beziehungsweise 92 Schritten erfordern; genau diese beiden Läufe heben die Mittelwerte von TD3 deutlich an. DDPG löst nur fünf, eher leichte Arenen, was seinen niedrigen Wert bei Metrik 1 erklärt. Tabelle 3 zeigt daher die Einzelergebnisse.

Tabelle 3: Ergebnisse je Seed. Ein Strich bedeutet, dass die Arena im Budget nicht gelöst wurde.

Seed	DDPG		TD3	
	Metrik 1	Metrik 2	Metrik 1	Metrik 2
0	–	–	121.118	26
1	–	–	32.362	23
2	1.235	27	10.022	25
3	–	–	250.901	35
4	–	–	144.963	83
5	3.185	26	3.192	25
6	–	–	45.808	24
7	7.228	23	3.151	23
8	4.573	22	279.128	92
9	6.146	23	2.301	23

Betrachtet man nur die fünf Seeds, die beide Verfahren lösen (2, 5, 7, 8 und 9), so liegt DDPG bei Metrik 1 im Mittel bei 4.473 Aufrufen und TD3 bei 59.559. Ohne den teuren Seed 8 sinkt

TD3 allerdings auf 4.667 Aufrufe und liegt damit gleichauf. Bei Metrik 2 sind beide Verfahren auf diesen Seeds nahezu identisch.

6. Fehlgeschlagene Versuche

6.1 Deterministischer Actor-Critic

Zuerst wurde ein deterministischer Actor-Critic umgesetzt, also im Kern DDPG ohne dessen Stabilisierungen. Dieser kollabierte zuverlässig auf die Nullaktion: Der Actor gab eine Beschleunigung nahe null aus, das Raumschiff blieb am Startpunkt stehen und überlebte bis zum Zeitlimit mit einer Belohnung von etwa null. Das ist aus Sicht des Agenten rational, weil Nichtstun keine Kollisionsstrafe kostet, während jeder Versuch, das Ziel zu erreichen, im Hindernisfeld endet. Erst eine deutlich verstärkte Exploration brachte ihn aus diesem lokalen Optimum heraus. Für die Abgabe wurde er durch den stochastischen Actor-Critic ersetzt, der näher an der Vorlesungsformulierung liegt.

6.2 Symmetrisches Reward-Clipping

Ein erster Versuch begrenzte die Belohnung symmetrisch auf $[-1, 1]$. Damit wurde zwar die Kollisionsstrafe gedämpft, gleichzeitig aber auch der Zielbonus auf denselben Betrag gestaucht. Da das Ziel nur äußerst selten erreicht wird, verlor es dadurch jede Sonderstellung gegenüber einer Kollision, und die Wertschätzungen kollabierten weiterhin. Erst die asymmetrische Variante aus Abschnitt 3 löste das Problem.

6.3 Zu weite Suchbereiche beim Tuning

Ein Tuning-Lauf des stochastischen Actor-Critic brach nach zwei Trials vollständig ab. Die Suchbereiche für die Lernraten waren zu weit gewählt, sodass Optuna Werte bis 0,245 für den Critic vorschlug. Bei solchen Lernraten divergiert der TD-Fehler, und der Entropiebonus treibt die gelernte Streuung der Politik unbegrenzt nach oben, bis sie numerisch überläuft und die Normalverteilung ungültig wird. Da Optuna Ausnahmen standardmäßig weiterreicht, beendete dieser eine Trial die gesamte Studie. Abhilfe schaffen engere Suchbereiche, die Begrenzung von `log_std` und das Abfangen fehlgeschlagener Trials, damit die Suche weiterläuft.

6.4 Schwache Exploration

Kleines Gauß-Rauschen um eine bereits kollabierte deterministische Politik reicht nicht aus. Der Agent zittert dann nur lokal um den Startpunkt und legt nie genug Strecke zurück, um das Ziel überhaupt zu finden. Notwendig war entweder korreliertes Rauschen oder das Einstreuen von Zufallsaktionen mit voller Magnitude.

7. Diskussion

Die größte Schwierigkeit dieser Aufgabe liegt in der Exploration und nicht in der Lernregel. Das Ziel liegt hinter einem dichten Hindernisfeld, und der Fortschrittsterm der Belohnung zeigt geradlinig darauf zu. Zustände näher am Ziel tragen dadurch ein höheres Kollisionsrisiko und einen niedrigeren Wert, sodass ein Agent es rational vermeidet, sich dem Ziel zu nähern. Genau das erzeugt die beiden beobachteten lokalen Optima, nämlich die Flucht in den freien Raum und das Verharren am Startpunkt.

Unter den ausgewerteten Verfahren ist TD3 mit Abstand das robusteste und löst als einziges alle zehn Arenen. Die drei Erweiterungen gegenüber DDPG wirken hier also genau wie beabsichtigt: Das Minimum zweier Critics verhindert, dass der Actor überschätzte Aktionswerte ausnutzt, was gerade bei der großen Kollisionsstrafe entscheidend ist. DDPG ist auf den Arenen, die es löst,

sehr stichprobeneffizient, scheitert aber an den schwereren Layouts. Bemerkenswert ist, dass die getunte TD3-Konfiguration einen Policy Delay von eins gewählt hat, die verzögerte Aktualisierung des Actors auf den Tuning-Seeds also keinen Vorteil brachte.

Erwartungsgemäß dürfte der stochastische Actor-Critic bei Metrik 1 schlechter abschneiden als die beiden off-policy Verfahren, da er jeden Übergang nur einmal verwendet und keinen Replay Buffer besitzt. Auf einer Aufgabe, bei der das Ziel so selten erreicht wird, wiegt das schwer, weil eine seltene erfolgreiche Episode sofort wieder verworfen wird, statt vielfach wiederverwendet zu werden.

8. Fazit

Verglichen wurden ein on-policy Verfahren und zwei off-policy Verfahren für kontinuierliche Aktionen, zusammen mit den Techniken, die das Lernen in dieser Umgebung überhaupt ermöglichen, also Eingangsnormalisierung, asymmetrisches Reward-Clipping und dauerhaft starke Exploration. TD3 ist das robusteste Verfahren und löst alle zehn Arenen, während DDPG nur die leichteren Layouts bewältigt, dort aber sehr stichprobeneffizient ist. Die Zahlen für den stochastischen Actor-Critic werden nach Abschluss seiner Auswertung ergänzt.

9. Quellen